Cahier des charges – Analyse ferroviaire (UK Train Rides)

Oct 26, 2026 · @Odzounalo Ofou Hance Welandi Cruz

1. Contexte et objectif

Ce projet sert de **preuve concrète de mes compétences en analyse de données** pour mes candidatures de stage, en priorité auprès de la SETRAG et d'AGL Gabon, présentes au Salon de l'Emploi des 5 et 6 novembre 2026.

Objectif : analyser l'activité voyageurs d'un réseau ferroviaire avec la chaîne Python (pandas) → SQL → Power BI, puis présenter des résultats chiffrés et des recommandations, comme le ferait un analyste au sein d'un opérateur ferroviaire.

Pourquoi ce jeu de données : il couvre les mêmes sujets que l'activité voyageurs de la SETRAG : ventes de billets, ponctualité, causes de retard et remboursements.

2. Problématique et questions d'analyse

Titre du projet : Analyse de la ponctualité et de la rentabilité d'un réseau ferroviaire de voyageurs

Problématique :

> Quels facteurs expliquent les retards et les annulations sur le réseau, et quel est leur impact sur les revenus de l'entreprise ?

Questions auxquelles le projet doit répondre :

1. Quel est le taux de ponctualité global, et comment varie-t-il selon les trajets, les jours et les heures ?
2. Quelles sont les principales causes de retard et d'annulation ?
3. Quels trajets rapportent le plus, et lesquels sont les plus touchés par les retards ?
4. Combien l'entreprise perd-elle en remboursements liés aux retards et annulations ?

Hors périmètre : le profil des voyageurs (âge, sexe), les coûts d'exploitation des trains et la météo réelle. Ces données ne sont pas dans le fichier.

3. Jeu de données

Source : UK Train Rides – Maven Rail Challenge (Kaggle), fichier *railway.csv*. Pas de dictionnaire de données fourni dans le ZIP.

Une ligne = un billet acheté pour un trajet. Ce n'est ni un train, ni un passager.

À vérifier sur mon fichier :

- [ ] Nombre de lignes et de colonnes (18 colonnes attendues)
- [ ] Période couverte : première et dernière date de voyage (normalement janvier – avril 2024)
- [ ] Mois complets ou non
- [ ] Valeurs vides légitimes : cause de retard vide si le train est à l'heure, arrivée réelle vide si le train est annulé

Dictionnaire des colonnes (à confirmer avec le fichier) :

Colonne	Signification	Type	Valeurs / exemple
Transaction ID	Identifiant unique du billet	Texte	Un code par ligne
Date of Purchase	Date d'achat du billet	Date	2023-12-08
Time of Purchase	Heure d'achat	Heure	12:41:11
Purchase Type	Canal d'achat	Catégorie	Online, Station
Payment Method	Moyen de paiement	Catégorie	Contactless, Credit Card, Debit Card
Railcard	Carte de réduction	Catégorie	Adult, Senior, Disabled, None (aucune)
Ticket Class	Classe du billet	Catégorie	Standard, First Class
Ticket Type	Type de tarif	Catégorie	Advance, Off-Peak, Anytime
Price	Prix payé	Nombre	En livres sterling (£)
Departure Station	Gare de départ	Texte	London Paddington…
Arrival Destination	Gare d'arrivée	Texte	Liverpool Lime Street…

Colonne	Signification	Type	Valeurs / exemple
Date of Journey	Date du voyage	Date	2024-01-01
Departure Time	Heure de départ prévue	Heure	11:00:00
Arrival Time	Heure d'arrivée prévue	Heure	13:30:00
Actual Arrival Time	Heure d'arrivée réelle	Heure	Vide si annulé
Journey Status	Statut du trajet	Catégorie	On Time, Delayed, Cancelled
Reason for Delay	Cause du retard ou de l'annulation	Catégorie	Weather, Signal Failure, Technical Issue, Staffing… Vide si à l'heure
Refund Request	Demande de remboursement	Catégorie	Yes, No

Points d'attention :

- Deux dates : achat et voyage. Pour la ponctualité, j'utilise la **date du voyage**.
- Deux heures d'arrivée : prévue et réelle. Leur écart donne la durée du retard.
- Une même cause de retard peut être écrite de deux façons (Weather / Weather Conditions, Staffing / Staff Shortage) : à regrouper.

4. Indicateurs à calculer

Chaque indicateur répond à une des quatre questions de la section 2.

Indicateur	Définition / calcul	Question
Nombre de billets	Nombre de lignes	Vue d'ensemble
Revenu total (£)	Somme de Price	Q3
Taux de ponctualité (%)	Billets « On Time » / total des billets	Q1
Taux de retard (%)	Billets « Delayed » / total des billets	Q1
Taux d'annulation (%)	Billets « Cancelled » / total des billets	Q1
Retard moyen (minutes)	Moyenne de (arrivée réelle − arrivée prévue), trajets en retard uniquement	Q1

Indicateur	Définition / calcul	Question
Répartition des causes (%)	Nombre de billets par cause / total des billets retardés ou annulés	Q2
Revenu par trajet (£)	Somme de Price par couple gare de départ – gare d'arrivée	Q3
Taux de retard par trajet (%)	Taux de retard calculé pour chaque trajet	Q3
Taux de demande de remboursement (%)	Billets avec Refund Request = Yes / billets retardés ou annulés	Q4
Montant exposé aux remboursements (£)	Somme de Price des billets avec Refund Request = Yes	Q4

Le dernier indicateur est une **estimation haute** : le fichier indique la demande de remboursement, pas le montant réellement remboursé. À préciser dans la synthèse.

5. Démarche

Six étapes, dans l'ordre. Je ne passe à la suivante que lorsque la précédente est terminée.

1. **Comprendre les données** (pandas)
   - Taille du fichier, types des colonnes, période couverte.
   - Valeurs possibles de chaque colonne texte.
   - Valeurs vides : légitimes ou anormales ?
   - Résultat : dictionnaire des colonnes vérifié (section 3).
2. **Nettoyer et préparer** (pandas)
   - Convertir les dates et les heures au bon format.
   - Harmoniser les causes de retard (même cause, même libellé).
   - Créer les colonnes utiles : trajet (départ – arrivée), durée du retard en minutes, mois, jour de la semaine, heure de départ.
   - Vérifier les incohérences : prix négatifs, doublons, arrivée avant départ.
   - Exporter *railway_clean.csv*.
3. **Calculer les indicateurs** (SQL)
   - Charger *railway_clean.csv* dans une base SQLite.
   - Écrire une requête par indicateur de la section 4.
4. **Construire le tableau de bord** (Power BI)
   - Page 1 – Vue d'ensemble : billets, revenu, taux de ponctualité, évolution mensuelle.

- Page 2 – Retards : causes, retard moyen, trajets et heures les plus touchés.
- Page 3 – Revenus et remboursements : trajets les plus rentables, montant exposé.
- Filtres : mois, type de billet, classe, canal d'achat.

5. **Rédiger la synthèse**
   - Réponse à la problématique en 2 phrases.
   - 3 à 5 résultats chiffrés.
   - 2 ou 3 recommandations concrètes.
6. **Publier**
   - Dossier GitHub avec README.
   - Post LinkedIn avec captures et lien GitHub.
   - Ligne ajoutée dans la rubrique « Projets » du CV.

6. Livrables

#	Livrable	Contenu	Outil
1	README	Problématique, source, dictionnaire des colonnes, démarche, résultats, captures	Markdown (GitHub)
2	Notebook de préparation	Exploration, nettoyage, nouvelles colonnes, export du fichier propre	Python / pandas
3	Requêtes SQL	Base de données + un fichier de requêtes pour les indicateurs	SQLite
4	Tableau de bord	3 pages + captures ou export PDF	Power BI
5	Synthèse	1 page : réponse à la problématique, résultats chiffrés, recommandations	Dans le README
6	Post LinkedIn	Problématique, captures, 3 résultats clés, lien GitHub	LinkedIn

Organisation du dossier GitHub :

```
analyse-ponctualite-ferroviaire/
├── README.md                          ← livrables 1 et 5
├── data/
│   ├── railway.csv                    ← données brutes
│   └── railway_clean.csv              ← données nettoyées
├── notebooks/
│   └── 01_exploration_nettoyage.ipynb ← livrable 2
├── sql/
│   └── indicateurs.sql                ← livrable 3
└── dashboard/
    ├── ponctualite_ferroviaire.pbix   ← livrable 4
    └── captures/
```

7. Planning jusqu'au salon

Objectif : le tableau de bord et la synthèse prêts avant le Nov 5, 2026. Le SQL passe après Power BI : je peux le terminer après le salon si le temps manque.

Étape	Dates	Statut
1. Comprendre les données	26 – 27 oct.	En cours
2. Nettoyer et préparer	28 – 29 oct.	À faire
4. Tableau de bord Power BI	30 oct. – 1er nov.	À faire
5. Synthèse	2 nov.	À faire
6. GitHub, LinkedIn et CV	3 nov.	À faire
3. Requêtes SQL	4 nov. ou après le salon	À faire

Avant le salon, je dois connaître par cœur 3 résultats chiffrés et 1 recommandation, et avoir les captures du tableau de bord sur mon téléphone.